Disciplina: Tópicos em Biotecnologia 2
Mestrado e Doutorado em Biotecnologia - PPGBiotec
Prof. Dr. Adonias Caetano de Oliveira
Aluna: Hellen Jasmine Pessoa Ferreira
Aluna: Maria Katriane de Sousa da Silva Oliveira

Avaliação de Modelos de Inteligência Artificial Aplicado na classificação de textos relacionados à saúde

Objetivo

Nosso objetivo foi proporcionar uma experiência prática no desenvolvimento e na avaliação de uma solução de Inteligência Artificial para leitura e classificação de textos, utilizando o modelo BERT (*Bidirectional Encoder Representations from Transformers*) em conjunto com um dataset específico para análise de sentimentos.

Ao longo da atividade, exploramos o processo de preparação e tratamento dos dados, o treinamento e a avaliação do modelo BERT, buscando identificar e classificar diferentes sentimentos presentes nos textos. Dessa forma, pudemos compreender, na prática, a aplicação de modelos baseados em Transformers em tarefas de Processamento de Linguagem Natural (PLN), utilizando Python e Google Colab ou outras ferramentas adequadas.

Metodologia

Conduzimos a atividade com base em etapas adaptadas da metodologia CRISP-DM, contemplando as seguintes etapas:

Compreensão do problema → Compreensão dos dados → Preparação dos textos → Modelagem → Avaliação → Análise dos resultados

Inicialmente, realizamos a exploração e a preparação do conjunto de dados, utilizando modelos baseados em **Transformers**, com foco no **BERT e BERTimbau**, que são modelos pré-treinados voltados ao processamento de linguagem natural.

Em seguida, adaptamos os modelos ao conjunto de dados selecionado, utilizando **fine-tuning** quando aplicável, com o objetivo de melhorar o desempenho na tarefa de classificação dos textos.

Também realizamos diferentes configurações experimentais, o que nos permitiu comparar o desempenho dos modelos e analisar as métricas de avaliação. A partir desses resultados, buscamos identificar as principais características, limitações e resultados obtidos pelos modelos na classificação dos textos.

1. Entendimento do Negócio (ou do Domínio)

a) Qual problema de saúde o dataset representa?

Utilizamos um conjunto de textos em português brasileiro relacionados à saúde mental, com foco em relatos de ideação suicida, sintomas psicológicos, depressão e possíveis situações de risco de suicídio. O dataset utilizado está relacionado ao contexto do Sistema Boamente, permitindo a análise de manifestações de sofrimento psicológico presentes na linguagem escrita.

b) Qual é o objetivo da tarefa de aprendizado de máquina? Classificação?

Nosso objetivo foi realizar uma tarefa de classificação supervisionada binária, na qual buscamos classificar os textos em duas categorias. A classe 0 representa a ausência de sintoma ou de relato relacionado à condição analisada, enquanto a classe 1 representa a presença de sintoma ou manifestação relacionada à ideação suicida.

c) Qual variável será prevista pelo modelo (variável-alvo)?

A variável-alvo utilizada no modelo foi a `label`, responsável por indicar a presença ou ausência do sintoma identificado no texto. Dessa forma, utilizamos o conteúdo textual presente na variável `text` para realizar a previsão da respectiva classe.

d) Qual seria a utilidade prática desse modelo na área da saúde?

A aplicação prática do modelo poderia auxiliar no acompanhamento da evolução de pacientes

e na identificação de possíveis sinais de sofrimento psicológico ou ideação suicida presentes em textos escritos. O sistema poderia funcionar como uma ferramenta de apoio para sinalizar possíveis situações de risco e auxiliar os profissionais na identificação de casos que necessitem de uma avaliação mais cuidadosa.

e) Quem poderia utilizar esse modelo?

O modelo poderia ser utilizado como ferramenta de apoio por equipes especializadas em saúde mental, incluindo principalmente psicólogos e psiquiatras.

f) Quais seriam as possíveis limitações ou riscos de utilizar esse modelo na prática?

Falsos Negativos: Um usuário com ideação suicida implícita ou metafórica não ser detectado e não receber ajuda imediata.
Falsos Positivos: Gatilhos ou desabafos sem intenção de autolesão gerarem alarmes falsos e sobrecarga da equipe.
Viés linguístico: Dificuldade com gírias, ironia, regionalismos e dependência de contexto que o modelo pode não captar.

2. Entendimento dos Dados

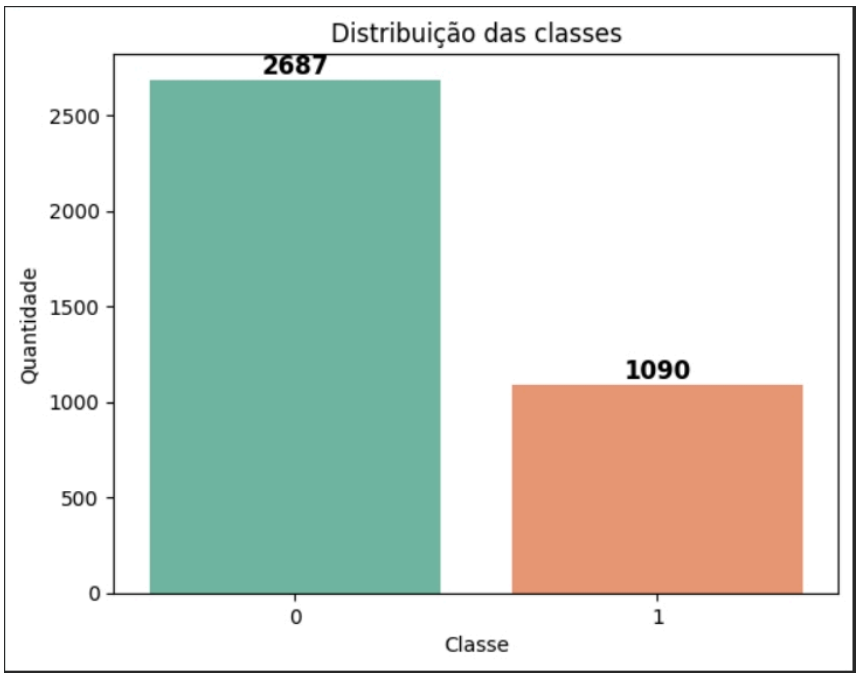
a) Qual a dimensão do dataset (quantidade de sentenças)?

3777 instâncias.

b) Caso tenha outras colunas além do texto e classe, o que representa cada atributo?

O código usa TEXT = "text" (o corpo do relato textual) e TARGET = "label" (o rótulo indicando sintoma ou ausência).

c) Como está distribuída a variável-alvo?



Sem sintoma, teve uma quantidade de instâncias encontrada de 2687 palavras e com sintoma obteve um total de 1090 instâncias encontradas. Esse valor serve para os 3 modelos.

d) O conjunto de dados é balanceado ou desbalanceado?

Ao analisarmos a distribuição das classes, observamos que o conjunto de dados apresenta desbalanceamento. A Classe 0 possui 2.687 instâncias, enquanto a Classe 1 possui 1.090 instâncias, correspondendo a uma proporção aproximada de 2,47:1. Dessa forma, a Classe 0 representa cerca de 71,1% do conjunto de dados, enquanto a Classe 1 representa 28,9%, indicando a necessidade de considerar esse desbalanceamento durante a etapa de modelagem e avaliação dos modelos.

e) Há algum atributo pouco relevante ou redundante?

Não.

f) Informações importantes observadas durante a exploração de dados?



A nuvem de palavras demonstra predominância de termos relacionados a **experiências pessoais, sentimentos e sofrimento emocional**. Observa-se uma frequência elevada de pronomes em primeira pessoa, como “eu”, “meu” e “minha”, indicando que os textos apresentam relatos centrados em experiências individuais. Também aparecem com destaque verbos e expressões associados a sentimentos e estados emocionais, como “quero”, “amar”, “amo”, “odeio”, “sinto” e “querer”. Além disso, termos como “dor”, “medo”, “ansiedade”, “triste”, “cansado”, “morrer” e “suicídio” aparecem de forma significativa, evidenciando a presença de conteúdos relacionados a sofrimento psicológico e emocional no conjunto analisado.

É importante destacar que a nuvem de palavras representa **frequência de ocorrência dos termos**, não sendo suficiente, isoladamente, para determinar a classificação emocional de um texto. A interpretação deve ser complementada pelas métricas e resultados obtidos pelo modelo BERT/BERTimbau.

3. Preparação dos Dados

a) Foi necessário realizar limpeza dos textos? Quais procedimentos foram utilizados?

Sim. Foi necessário realizar a limpeza dos textos como etapa de pré-processamento dos dados, com o objetivo de eliminar informações que poderiam gerar ruídos e prejudicar a análise textual.

Foram realizados os seguintes procedimentos: remoção de menções (@usuário), para eliminar referências específicas a outros usuários; remoção de tags HTML, para retirar elementos de formatação que não fazem parte do conteúdo textual; remoção de números e dígitos, quando considerados irrelevantes para a análise; remoção de URLs, pois os links não representam diretamente o conteúdo semântico dos textos; e remoção de sinais de pontuação, contribuindo para a padronização dos dados e facilitando as etapas posteriores de processamento e análise.

Dessa forma, a limpeza permitiu trabalhar com textos mais uniformes e concentrados nas informações relevantes, tornando os dados mais adequados para as análises realizadas posteriormente.

b) Foram encontrados textos ausentes, vazios, duplicados ou com erros?

Não foi verificada a duplicação, podendo ser um ponto de melhoria.

c) Foi realizada normalização ou pré-processamento textual? Por quê?

Sim. Foi realizada uma etapa de normalização e pré-processamento textual com o objetivo de reduzir ruídos presentes nos textos coletados de redes sociais e tornar os dados mais adequados para a análise.

Durante esse processo, foram removidos elementos como pontuações, dígitos, URLs e menções a usuários. Além disso, o tokenizer foi configurado com `do_lower_case=True`, fazendo com que os textos fossem convertidos para letras minúsculas e, consequentemente, tratados de maneira mais uniforme.

A principal finalidade desse pré-processamento foi eliminar elementos característicos das redes sociais que poderiam interferir na análise, especialmente URLs e menções, mantendo o foco no conteúdo textual. Entretanto, é importante destacar que, em modelos baseados em Transformers, como o BERTimbau, a remoção de pontuação e a conversão para letras minúsculas devem ser consideradas com cautela. Em modelos *cased*, por exemplo, a pontuação, a capitalização e a estrutura original das frases podem contribuir para a compreensão do contexto sintático e de aspectos relacionados à expressão emocional.

Assim, o pré-processamento adotado teve como foco principal a limpeza dos ruídos dos dados, embora seja importante considerar que algumas dessas transformações podem ocasionar perda de informações linguísticas relevantes para modelos que utilizam o contexto da frase.

d) Como os textos foram representados numericamente para os modelos?

Foi utilizada a tokenização do próprio BERT (WordPiece / subwords) convertida em tensores contendo:input_ids: índices dos tokens no vocabulário do modelo.attention_mask: máscara binária diferenciando tokens reais (1) de preenchimento/padding (0).

e) Houve seleção ou redução de atributos/vocabulário?

Não foi necessária seleção manual (como corte por frequência ou TF-IDF), pois o vocabulário é fixo e pré-treinado do BERTimbau (cerca de 29.794 tokens), tratando palavras fora do vocabulário via divisão em subpalavras (##).

f) Como foi tratada a distribuição das classes?

O dataset foi mantido em sua distribuição original.

g) Como o conjunto de dados foi dividido?

Divisão em Treino (64%), Validação (16%) e Teste (20%) (já que 20% do restante de 80% é 16%).

h) Como os rótulos foram preparados para o treinamento?

Mapeamento categórico para numérico ('sem_sintoma': 0, 'sintoma': 1) e posterior conversão para torch.LongTensor para cálculo da perda (CrossEntropyLoss interna do modelo).

4. Modelagem

a) Quais modelos ou abordagens foram utilizados?

Foram comparadas três variações da arquitetura BERT (Bidirectional Encoder Representations from Transformers) pré-treinadas e ajustadas via fine-tuning:

BERTimbau Base (neuralmind/bert-base-portuguese-cased): Modelo monolíngue de 12 camadas (layers), 768 unidades ocultas e 110M de parâmetros, pré-treinado no corpus BrWaC (Português Brasileiro).

BERTimbau Large (neuralmind/bert-large-portuguese-cased): Versão de maior capacidade representacional, composta por 24 camadas, 1024 unidades ocultas e ~335M de parâmetros, também pré-treinada especificamente em Português Brasileiro.

mBERT / Multilingual BERT (bert-base-multilingual-cased): Modelo pré-treinado pelo Google cobrindo 104 idiomas simultaneamente (incluindo o português), com 12 camadas e ~178M de parâmetros.

b) Por que esses modelos/abordagens foram escolhidos?

Adequação Linguística: O problema envolve textos em língua portuguesa com linguagem informal e nuances de saúde mental. O BERTimbau foi escolhido por ter sido pré-treinado diretamente com vocabulário e morfossintaxe do português brasileiro.

Avaliação de Capacidade (Base vs. Large): A comparação entre as versões Base e Large do BERTimbau permite investigar se o aumento expressivo de parâmetros e profundidade da rede (de 110M para 335M) traz ganhos reais de desempenho na detecção de sintomas ou se acarreta sobreajuste (overfitting) e custo computacional desnecessário para o tamanho do dataset.

Especialização vs. Generalização (Monolíngue vs. Multilíngue): A inclusão do bert-base-multilingual-cased serve para testar se uma representação multilíngue ampla é suficiente para a tarefa ou se o pré-treinamento dedicado ao português (BERTimbau) oferece

vantagens semânticas decisivas na identificação de relatos de sofrimento psíquico.

c) Como cada modelo recebeu os textos como entrada?

Todos os três modelos receberam os textos tokenizados via algoritmos de subpalavras (WordPiece), convertidos nas seguintes estruturas de entrada com comprimento máximo fixado em 128 tokens (MAX_LENGTH = 128): input_ids: Sequência numérica de identificadores de tokens, delimitada obrigatoriamente pelos tokens especiais [CLS] (no início, usado para captar a representação da frase inteira) e [SEP] (no fim). Attention_mask: Vetor binário onde o valor 1 indica tokens textuais reais e 0 indica preenchimento (padding) para uniformizar o tamanho do lote. O vocabulário do BERTimbau (Base e Large) possui cerca de 29.794 tokens específicos do português, enquanto o mBERT utiliza um vocabulário compartilhado de 119.547 tokens para cobrir múltiplos idiomas.

d) Como os modelos foram configurados (Hiperparâmetros)?

Para assegurar uma comparação justa e controlada, os três modelos foram treinados sob os mesmos hiperparâmetros de base:
Tamanho do lote (Batch size): 16,
Número de épocas: 7 épocas,
Otimizador: AdamW,
Taxa de aprendizado (Learning Rate): 2e-6
Agendador (Scheduler): get_linear_schedule_with_warmup (com decaimento linear e sem passos de aquecimento)
Regularização: Gradient Clipping com max_norm = 1.0 para evitar a explosão de gradientes (exploding gradients).

e) No caso de BERT, como o modelo foi utilizado?

Os três modelos foram carregados com suas matrizes de pesos pré-treinadas a partir do Hugging Face Hub e acoplados a uma cabeça de classificação linear (BertForSequenceClassification) configurada com num_labels = 2. Não foi feito apenas feature extraction (congelamento das camadas base): todos os parâmetros internos das camadas de atenção e da camada de saída foram atualizados conjuntamente via fine-tuning supervisionado de ponta a ponta (end-to-end) minimizando a perda por entropia cruzada (CrossEntropyLoss).

f) No caso de LLMs, como foi realizada a classificação?

Não aplicável.
O presente trabalho delimitou o estudo experimental à comparação de três arquiteturas baseadas em Transformers de representação contextual bidirecional (BERTimbau Base, BERTimbau Large e Multilingual BERT) submetidas a fine-tuning supervisionado de ponta a ponta. Não foram empregados Grandes Modelos de Linguagem (LLMs) gerativos (como LLaMA ou Qwen) via técnicas de prompting ou inferência gerativa, uma vez que o foco investigativo residiu no impacto da especialização linguística e da capacidade paramétrica dentro da família BERT para a classificação supervisionada em língua portuguesa.

g) Como foi implementado o experimento?

O experimento foi desenvolvido em ambiente Google Colab com aceleração por hardware via GPU (Nvidia T4/V100 com CUDA). Foram utilizadas as bibliotecas:
PyTorch e torch.utils.data (para estruturas de tensores, DataLoader e rotina de treinamento/otimização);
Hugging Face Transformers (para carregamento dos tokenizadores e arquiteturas BERT);
Scikit-learn (para métricas e matriz de confusão);
LIME (Local Interpretable Model-agnostic Explanations) para explicabilidade das predições;
Matplotlib e Seaborn para geração dos gráficos de perda e distribuição.

h) As mesmas condições experimentais foram utilizadas na comparação?

Sim. A divisão dos dados manteve estritamente a mesma semente aleatória (random_state=42) para todas as execuções, garantindo que os três modelos fossem treinados exatamente no mesmo subconjunto de treino (64%), monitorados no mesmo conjunto de validação (16%) e avaliados no mesmo conjunto de teste (20%). O pré-processamento textual, o comprimento máximo de tokens (128) e a métrica de parada foram idênticos.

5. Avaliação dos Modelos

classifiation report- BERTimbau Large
(neuralmind/bert-large-portuguese-cased)

Classe / Métrica	Precisão	Recall (Revocação)	F1-Score	Suporte (Amostras)
Negative (Sem Sintoma)	0,94	0,95	0,94	531
Positive (Com Sintoma)	0,88	0,85	0,86	225
Acurácia Global	—	—	0,92	756

classifiation report : mBERT / Multilingual BERT
(bert-base-multilingual-cased)

Classe / Métrica	Precisão	Recall (Revocação)	F1-Score	Suporte (Amostras)
Negative (Sem Sintoma)	0,90	0,94	0,92	415
Positive (Com Sintoma)	0,86	0,77	0,81	190SS
Acurácia Global	—	—	0,89	605

classifiation report : BERTimbau Base
(neuralmind/bert-base-portuguese-cased)

Classe / Métrica	Precisão	Recall (Revocação)	F1-Score	Suporte (Amostras)
Negative (Sem Sintoma)	0,94	0,95	0,95	533
Positive (Com Sintoma)	0,88	0,86	0,87	223
Acurácia Global	—		0,92	756

a) Quais métricas de avaliação foram utilizadas?

Acurácia, Precisão, Revocação (Recall), F1-Score (macro e ponderada) e Matriz de Confusão Normalizada.

b) Qual modelo ou abordagem apresentou o melhor desempenho?

O BERTimbau Base apresentou o melhor desempenho geral. Embora tenha empatado em acurácia global com o BERTimbau Large (92%), o BERTimbau Base obteve o maior Recall na classe crítica de interesse (Com Sintoma: 0,86) e o maior F1-Score (0,87). Em problemas de triagem em saúde, a sensibilidade/revocação na classe patológica é a métrica prioritária para minimizar falsos negativos.

c) Os resultados obtidos são satisfatórios para o problema?

Os resultados obtidos são satisfatórios para o problema de classificação?Sim, resultados com acurácia acima de 90% e F1-score de 0,87 na classe positiva indicam que a representação contextual bidirecional pré-treinada em português captura adequadamente as expressões de sofrimento psíquico. Contudo, para aplicação clínica autônoma, uma taxa de 14% de falsos negativos (1 - Recall de 0,86) ainda exige que a ferramenta funcione apenas como suporte à decisão ou triagem sob supervisão humana contínua.

d) Quais diferenças foram observadas entre os modelos testados?

Especialização Linguística (BERTimbau vs. mBERT): Ambos os modelos BERTimbau superaram expressivamente o mBERT, especialmente no Recall da classe com sintoma (0,86 e 0,85 contra 0,77 do mBERT). Isso comprova que a tokenização dedicada ao português brasileiro preserva nuances semânticas e expressões coloquiais de saúde mental que o vocabulário genérico compartilhado do mBERT fragmenta excessivamente (over-tokenization). Capacidade Paramétrica (Base vs. Large): O BERTimbau Large (~335M parâmetros) não trouxe ganhos em relação ao Base (~110M parâmetros), apresentando métricas praticamente idênticas e até um ponto percentual a menos no Recall da classe positiva (0,85 vs. 0,86). Considerando o custo computacional e tempo de treinamento cerca de 3 vezes maior do modelo Large, o BERTimbau Base mostrou-se a melhor escolha sob a ótica de custo-benefício e eficiência.

e) Quais classes foram mais fáceis ou difíceis de identificar?

Mais fácil: A classe "Sem Sintoma" obteve métricas superiores em todos os modelos (F1 entre 0,92 e 0,95), beneficiada pelo maior volume de amostras de suporte (maior prevalência no conjunto de dados). Mais difícil: A classe "Com Sintoma" apresentou menor Recall em todas as configurações (variando de 0,77 no mBERT a 0,86 no BERTimbau Base). Isso reflete a maior complexidade linguística da dor psíquica, que frequentemente envolve metáforas, desabafos sutis ou termos ambíguos.

f) Quais erros ocorreram com maior frequência?

Em problemas binários de detecção de sintomas de saúde mental, os erros dividem-se em Falsos Negativos (FN) e Falsos Positivos (FP):Falsos Negativos (FN — Maior gravidade clínica): Ocorreram quando o modelo classificou um texto que continha sofrimento psíquico/sintoma como sem sintoma (classe 0).No BERTimbau Base, com Recall de 0,86 na classe positiva, a taxa de FN foi de aproximadamente 14% das ocorrências reais de sintomas (cerca de 31 amostras não detectadas em 223). No mBERT, com Recall de 0,77, a taxa de FN subiu para 23%, demonstrando que quase 1 em cada 4 pessoas com sintomas passaria despercebida. Falsos Positivos (FP — Menor gravidade clínica, porém gerador de sobrecarga): Ocorreram quando desabafos cotidianos sem gravidade clínica foram classificados como com sintoma (classe 1).Nos modelos BERTimbau (Base e Large), a Precisão foi de 0,88, indicando que aproximadamente 12% dos alertas emitidos foram falsos alarmes. Conclusão de confusão: A classe "Com Sintoma" foi mais confundida como "Sem Sintoma" (FN) do que o oposto, principalmente pela presença de desabafos implícitos e metáforas linguísticas que não ativaram fortemente os pesos associados à ideação ou dor psíquica.

g) Características dos textos associadas aos erros:

A análise qualitativa das predições incorretas (filtradas no dataframe erros) e as interpretações geradas pelo LIME apontam quatro fatores linguísticos determinantes para as falhas:Presença de Negação Sintática: Sentenças como "Hoje não estou triste" ou "Não sinto mais vontade de morrer" frequentemente induzem o modelo ao erro (gerando Falsos Positivos). O modelo ancora alta atenção em termos com carga emocional forte ("triste", "morrer"), falhando pontualmente em inverter o peso da predição com base no operador de negação ("não").Textos Muito Curtos ou Ambíguos: Relatos monossilábicos ou expressões vagas (ex.: "cansado de tudo", "acabou") carecem de contexto semântico suficiente para que o mecanismo de atenção

diferencie cansaço rotineiro de exaustão psicológica grave.Metáforas e Linguagem Figurativa: O uso de ironias, humor autodepreciativo ou expressões figuradas comuns em redes sociais cria sobreposição lexical entre desabafos inofensivos e sintomas reais.Remoção de Pontuações no Pré-processamento: A limpeza inicial que removeu pontuações (string.punctuation) e converteu caracteres para minúsculas prejudicou a retenção de ênfases emocionais (pontos de exclamação, reticências, caixas altas de desespero), elementos que fornecem pistas contextuais cruciais aos Transformers.

h) O modelo seria adequado para aplicação em um contexto real de saúde?

Não para diagnóstico ou tomada de decisão autônoma. O modelo pode ser considerado adequado apenas como ferramenta de suporte à triagem (Decision Support System) operando sob o paradigma Human-in-the-Loop (supervisão humana estrita). A justificativa apoia-se em cinco dimensões críticas:Consequência dos Erros: O impacto de um Falso Negativo em saúde mental pode ser fatal (a não identificação de risco iminente de autolesão/suicídio). Uma taxa de omissão de 14% impede qualquer automação irrestrita. Sobrecarga por Falsos Positivos: Embora clinicamente mais seguros que os FNs, alarmes falsos excessivos (12%) geram saturação e fadiga de alerta nos profissionais de saúde. Privacidade e Ética (LGPD): O processamento de dados de saúde mental envolve dados pessoais altamente sensíveis. A implementação real exigiria anonimização prévia de entidades nomeadas (nomes, cidades, contatos) e consentimento explícito.Generalização e Vieses: Redes sociais e fóruns tendem a concentrar dados de faixas etárias específicas (jovens/adultos jovens), o que gera viés de distribuição (domain shift); o modelo pode apresentar desempenho significativamente inferior se aplicado a idosos ou crianças com vocabulários clínicos distintos.

i) O que poderia ser feito para melhorar os resultados?

Para mitigar os erros observados e aumentar a confiabilidade clínica do sistema, recomendam-se as seguintes intervenções:Revisão do Pipeline de Pré-processamento: Preservar a pontuação, acentuação e a caixa alta/baixa do texto original. O BERTimbau foi pré-treinado no formato cased, e recursos de pontuação carregam carga afetiva essencial em textos de desabafo.Mitigação do Desbalanceamento: Utilizar técnicas de reponderação de função de perda (Class Weighted Cross-Entropy Loss) ou Focal Loss, penalizando com maior rigor os Falsos Negativos durante a retropropagação.Divisão Estratificada dos Dados: Aplicar Stratified K-Fold Cross Validation ou stratify=Y no train_test_split, garantindo que as proporções originais de classes sejam preservadas estritamente em treino, validação e teste.Fine-Tuning de Modelos de Domínio Específico: Avaliar variantes do BERT especializadas na literatura

biomédica ou clínica em língua portuguesa (como BioBERTpt), que compreendem termos farmacológicos e clínicos com maior precisão vetorial.Combinação Híbrida / Ensembles: Integrar o classificador BERT a regras baseadas em dicionários de termos de alto risco (léxicos de risco de suicídio), forçando a priorização do Recall para qualquer menção a métodos ou ideação explícita.